

## 6.5. Manual de usuario

En esta sección presentamos un manual de usuario sencillo y exhaustivo en el que se explica con sumo detalle en qué consiste la aplicación y cómo usarla. Se ha redactado de tal forma que cualquier usuario pueda hacer uso de ella, quedando bajo su responsabilidad e interés el saber interpretar los resultados gráficos que se obtienen al ejecutar ciertas funcionalidades de la misma.

### 6.5.1. ¿Qué es esta aplicación?

Esta aplicación permite analizar datos de expresión génica (es decir, los niveles de actividad de diferentes genes en distintas muestras biológicas). Usted no necesita saber de matemáticas ni de informática, incluso ni de biología para poder usarla; la propia app le guía paso a paso y muestra gráficos que resumen resultados obtenidos. Si lo que le interesa es interpretar correctamente los resultados, es recomendable que conozca de antemano el estudio del que provienen los datos, como mínimo, y tenga algunos conocimientos básicos, o bien se apoye de alguien que los tenga.

### 6.5.2. ¿Qué necesita para usarla?

Tan solo necesita:

- Un archivo en formato CSV (.csv) o TSV (.tsv) que contenga los datos.
- Un ordenador con conexión a Internet, si ejecuta la aplicación online, y tener R o Shiny instalados si se hace de forma local.

El archivo debe tener los nombres de los genes en la primera columna (los identificadores, generalmente), los nombres de las muestras en la primera fila y solo números en las celdas, que serán los niveles de expresión. Por ejemplo:

| Gen | Muestra1 | Muestra2 | Muestra3 |
|-----|----------|----------|----------|
| A   | 4.5      | 3.9      | 4.1      |
| B   | 5.0      | 6.0      | 2.9      |

Tabla 6.1: Ejemplo del contenido de un fichero con datos de expresión

### 6.5.3. ¿Cómo iniciar la aplicación?

Puede iniciar la aplicación de dos formas distintas:

- En línea, simplemente haciendo click en el enlace proporcionado: <https://5t9bge-quintin-mesa@romero.shinyapps.io/RNAseq-Vision/>.
- En local, para lo cual tendrá que abrir el archivo *app.R* en *Rstudio* (previa descarga del código fuente) y pulsar el botón *Run App* en la parte superior.




Figura 6.1: Botón Runapp RStudio (Fuente: elaboración propia).

#### 6.5.4. Estructura de la pantalla

Una vez iniciada la aplicación, se abrirá la página que puede ver en la figura 6.2:




Figura 6.2: Interfaz de usuario (Fuente: elaboración propia).

En ella, verá:

- Una cabecera con el título de la aplicación y el logo de la Universidad de Granada.
- A la izquierda, por debajo de la cabecera, una barra lateral donde podrá:
  - Subir su fichero con los datos.
  - Seleccionar el tipo de separador (coma, punto y coma, tabulador).
  - Indicar si los números decimales están escritos con coma o punto.
- En la parte principal, a la derecha de la barra lateral, verá:
  - Un menú con tres botones: PCA, Análisis Cluster, Expresión Diferencial.
  - Gráficos y resultados que se actualizan según los botones que pulse.

- En la panel lateral, tiene a su disposición un botón *Reset* con el que puede deshacer todas las acciones y volverá todo al estado justamente posterior a la carga de datos.
- A pie de página verá tres enlaces:
  - Un enlace al manual sobre el manejo de la aplicación, que está usted leyendo en estos momentos.
  - Un enlace de descarga del código fuente desde un repositorio público de *Google Drive*: [https://drive.google.com/uc?export=download&id=1VQpCryXb\\_0B54bNhIEOC5kvkDHCKW5nJ](https://drive.google.com/uc?export=download&id=1VQpCryXb_0B54bNhIEOC5kvkDHCKW5nJ).
  - Un enlace a una página en la que se muestra información de contacto del desarrollador de la aplicación, por si usted tuviera necesidad de comunicarse con el mismo.

### 6.5.5. ¿Cómo subir los datos?

Para subir los datos y poder hacer análisis multivariante con ellos, deberá seguir los siguientes pasos:

- Haga click en el botón *Subir archivo* de la barra lateral.
- Se abrirá el explorador de archivos de su ordenador, donde deberá buscar el archivo que contiene los datos. Puede descargar el fichero de datos de prueba ...raw\_counts en <https://www.ncbi.nlm.nih.gov/geo/download/?acc=GSE92914>
- Seleccione el separador correcto:
  - Coma (,) si los valores están separados por comas en el fichero.
  - Punto y coma (;) si vienen de Excel.
  - Tabulador si están separados por espacios grandes.
- Seleccione si los decimales estarán escritos con punto (.) o coma (,).
- Pulse el botón *Cargar datos* para cargar los datos del fichero.
- Una vez cargado correctamente, podrá ir a las secciones de análisis.

Estos mismos pasos se indican en la propia barra lateral de la interfaz, para guiarlo en todo el proceso, que puede resultar confuso.

Al pulsar el botón *Cargar datos*, necesario pulsarlo para ver los resultados, pueden surgir algunos errores por diferentes causas que se detallan a continuación:

- Si no ha seleccionado ningún fichero de su gestor de archivos, obtendrá el mensaje de error de la figura 6.3.



Figura 6.3: Error ningún fichero seleccionado (Fuente: elaboración propia).

- Si ha seleccionado mal el separador de los distintos registros de su fichero, obtendrá el aviso de la figura 6.4.




Figura 6.4: Separador posiblemente erróneo (Fuente: elaboración propia).

- Si no ha seleccionado ningún separador, verá el aviso de la figura 6.5.




Figura 6.5: Ningún separador seleccionado (Fuente: elaboración propia).

- Si no ha seleccionado ningún símbolo decimal, el mensaje que obtendrá será el de la figura 6.6.



Figura 6.6: Ningún símbolo decimal seleccionado (Fuente: elaboración propia).

#### 6.5.6. PCA (Análisis de Componentes Principales)

Si pulsa sobre el botón *PCA* del menú en línea de la parte principal, se hará todo el proceso correspondiente al Análisis de Componentes Principales con los datos que haya subido. El PCA sirve para reducir la complejidad de los datos y poder

deshacernos de variables que no aportan mucho al estudio, o lo que es lo mismo, que explican muy poca varianza. Además, nos dará pistas acerca de una posible agrupación de los mismos.

### ¿Qué verá?

Tras unos segundos de espera mientras se hacen todos los cálculos, podrá ver un gráfico con puntos de colores que representan las muestras de su conjunto de datos. Cada eje (PC1, PC2) representa una combinación de genes. Verá también otro gráfico que mostrará cuánta información contiene cada eje (varianza explicada por las distintas componentes principales).




Figura 6.7: Análisis de Componentes Principales (PCA) (Fuente: elaboración propia).

### ¿Qué tiene que hacer usted?

Nada, solamente tiene que limitarse a cargar los datos. El análisis lo hace automáticamente por debajo. Tras él, con el apoyo de los gráficos, podrá sacar sus propias conclusiones en función de sus intereses.

Una interpretación básica puede ser la siguiente:

- Si ve puntos juntos: esas muestras se parecen.
- Si ve puntos alejados: son diferentes.
- Si en el gráfico de la varianza observa que hay barras muy altas en comparación con otras, significa que estas explican mucha más información que otras y por tanto, podríamos deshacernos de ellas de cara al análisis.

#### 6.5.7. Análisis Cluster

Si pulsa sobre el botón *Análisis Cluster*, es porque quiere realizar clustering sobre los datos cargados. El análisis cluster sirve para agrupar las muestras en grupos disjuntos

que se llaman *clusters*. Al hacer click, se abren dos opciones:

- **Jerárquico:** se muestra un dendrograma (un árbol cuyas hojas son las muestras y que representa la agrupación jerárquica de las muestras del conjunto de datos, según similitud. Cada bifurcación une dos grupos o elementos similares, y la altura de la unión indica cómo de diferentes son. Se puede cortar a una determinada altura para definir el número de clusters).




Figura 6.8: Análisis cluster jerárquico - Dendrograma (Fuente: elaboración propia).

- **No jerárquico:**
  - Primero puede determinar cuál podría ser el mejor número de clusters en los que puede agrupar las muestras. Aparecerán dos opciones:
    - **Método del codo:** al hacer click, se mostrará un gráfico que tiene una *curva*. En el eje X, se disponen distintos valores para el número de clusters (k). En el punto de la gráfica en el que se aprecie un *codo*, se encuentra el mejor número de clusters.




Figura 6.9: Método del codo (Fuente: elaboración propia).

- *Método de la silueta*: muestra también una gráfica de forma que el punto en el que la gráfica alcance su máximo, ese será el candidato a número óptimo de clusters.




Figura 6.10: Método de la silueta (Fuente: elaboración propia).

- Luego, verá una barra horizontal deslizante con la que podrá elegir el número de clusters con el que aplicar el algoritmo k-means.
- Pulsando finalmente sobre el botón *Ejecutar K-means* tras haber escogido el número óptimo de clusters, verá un gráfico con los distintos grupos que se habrán formado, en colores diferentes para distinguirlos.




Figura 6.11: Método K-means (Fuente: elaboración propia).

### 6.5.8. Análisis de Expresión Diferencial

Al pulsar el botón *Expresión diferencial*, la aplicación realiza un análisis estadístico para identificar genes cuya expresión varía significativamente entre condiciones.

La tabla resultante muestra las siguientes columnas principales:



## 6 Aplicación para el análisis multivariante de datos transcriptómicos (RNA-Seq): diseño y desarrollo

- *baseMean*: expresión promedio del gen en todas las muestras.
- *log2FoldChange*: cambio en la expresión entre condiciones (en escala logarítmica base 2).
- *lfcSE*: error estándar del cambio estimado.
- *stat*: estadístico del test de comparación.
- *pvalue*: probabilidad de que el cambio sea por azar.
- *padj*: p-valor ajustado para controlar falsos positivos; valores menores a 0.1 indican significancia.

Esta información le permitirá identificar genes con cambios significativos en la expresión entre los grupos analizados.