

Metodologías Multivariantes para la Identificación de Patrones Biológicos

Doble Grado en Ingeniería Informática y Matemáticas
(Curso 2024-2025)


Quintín Mesa Romero



Tutor: José Luis Romero Béjar
Departamento de Estadística e Investigación
Operativa
June 23, 2025

- 1 Datos ómicos
- 2 Transcriptómica: RNA-seq
- 3 Técnicas multivariantes
 - Análisis de Componentes Principales (PCA)
 - Análisis Cluster
 - Medidas de disimilaridad
 - Medidas de similaridad
 - Métodos de agrupación en análisis cluster
 - Métodos jerárquicos
 - Métodos no jerárquicos
 - Determinación del número óptimo de clusters
- 4 Proyecto GEO
- 5 Bioconductor
- 6 Aplicación práctica

¿Qué son los datos ómicos?

**Matriz de expresión**

Filas: genes / proteínas / metabolitos

Columnas: muestras (individuos)

Alta dimensionalidad: muchas variables, pocas muestras

Observación: En transcriptómica, cada fila representa un gen y cada celda su expresión en una muestra.

Estructura de los datos: matriz de expresión

$$X = [x_{ij}]_{i=1,\dots,N, j=1,\dots,n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Nn} \end{bmatrix}$$

donde x_{ij} cuantifica la característica i en la muestra j , N el número de características observadas y n el número de individuos sobre los que se observan ($N \gg n$).

Observación

- Filas de la matriz de expresión = *perfiles de expresión*.
- Variables que describen y caracterizan a las muestras = variables fenotípicas (fenotipos).

Problema Estadístico: alta dimensionalidad en datos ómicos

- En estadística clásica, $n \gg N$ (muchas muestras, pocas variables).
- En datos ómicos: $N \gg n$ (miles de genes, pocas muestras).
- Esto dificulta la construcción de modelos predictivos fiables.

Dificultades adicionales

- Fenómenos geométricos contraintuitivos en alta dimensión.
- Herramientas estadísticas diseñadas para espacios de baja dimensión pierden efectividad.
- Maldición de la dimensionalidad.

¿Qué es la transcriptómica?

Estudia el conjunto completo de ARN (transcriptoma) expresado en una célula o tejido en un momento y condición específicos. Incluye mARN, tARN, rARN y ncARN.

Tecnologías para estudiar el transcriptoma

- Microarrays
- Secuenciación: RNA-seq, scRNA-seq

Contexto actual

RNA-seq y single-cell RNA-seq principales técnicas de secuenciación de ARN.

¿Qué es RNA-seq?

- Técnica basada en secuenciación masiva para cuantificar ARN.
- Convierte ARN en ADNc que se fragmenta y secuencia.
- Permite medir la expresión génica en distintas condiciones biológicas.

Datos RNA-seq

- Datos masivos con estructura matricial: $N \gg n$.
- Almacenamiento en formatos estándar: FASTA y FASTQ.

```

1 @SRR1293399.1 ILLUMINA-545855_0026_FC629BG:6:1:1022:5049 length=50
2 ACAGGGACGCCATCGAATCCGGATCNTNNNNNNNNNNNNNNNNNNNNNN
3 +SRR1293399.1 ILLUMINA-545855_0026_FC629BG:6:1:1022:5049 length=50
4 dee\edYcdc`bbY`S]bb_]Ua^BBBBBBBBBBBBBBBBBBBBBBBB
5
```

Figure 1: Formato FASTAQ (Fuente: elaboración propia).

Análisis de Componentes Principales (PCA)

Técnica multivariante para reducir la dimensionalidad de un conjunto de variables correlacionadas transformándolas en un conjunto menor de variables no correlacionadas llamadas **componentes principales** (CP).

Objetivo

Condensar la información proporcionada por dichas variables en pocas combinaciones lineales que capturan la **máxima variabilidad** posible.

¿Cómo se definen las componentes principales?

Sea $Y = (Y_1, Y_2, \dots, Y_N)'$ un vector de variables con media μ y matriz de covarianza Σ . Las **componentes principales** se definen como:

$$Z_i = p_i' Y, \quad i = 1, 2, \dots, N$$

donde p_i es un vector de pesos que maximiza la varianza de Z_i :

$$\max_{p_i} \text{Var}(Z_i) = p_i' \Sigma p_i, \quad \text{sueto a } p_i' p_i = 1$$

y garantizando que las CP sean ortogonales:

$$p_i' p_j = 0, \quad i \neq j$$

Interpretación

Los vectores p_i son los autovectores de Σ , y los valores propios λ_i indican la varianza explicada por cada componente principal. La transformación completa es:

$$Z = P' Y$$


donde P es la matriz de autovectores.

Análisis Cluster

Técnica exploratoria para **agrupar objetos no etiquetados** en *clusters*:

- Alta **similitud** interna
- Alta **diferencia** externa
- No requiere categorías previas

Ejemplo



Medidas de disimilaridad

Minkowski (general)

$$d_{ij} = \left\{ \sum_{k=1}^p |x_{ik} - x_{jk}|^r \right\}^{\frac{1}{r}}$$

Euclídea (L_2)

$$d_2(x_i, x_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

Manhattan (L_1)

$$d_1(x_i, x_j) = \sum_{k=1}^p |x_{ik} - x_{jk}|$$

Chebychev (L_∞)

$$d_\infty(x_i, x_j) = \max_{k=1, \dots, p} |x_{ik} - x_{jk}|$$

Mahalanobis

$$D_\Sigma(x_i, x_j) = \sqrt{(x_i - x_j)' \Sigma^{-1} (x_i - x_j)}$$

Medidas de similaridad

Coeficiente de Pearson

$$q_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_{i.})(x_{jk} - \bar{x}_{j.})}{[\sum_{k=1}^p (x_{ik} - \bar{x}_{i.})^2 \sum_{k=1}^p (x_{jk} - \bar{x}_{j.})^2]}$$

donde $\bar{x}_{i.} = \frac{1}{p} \sum_{k=1}^p x_{ik}$, $\bar{x}_{j.} = \frac{1}{p} \sum_{k=1}^p x_{jk}$

Coseno del ángulo θ

$$c_{ij} = \cos \theta = \frac{x'_i x_j}{\|x_i\| \|x_j\|}$$

Notas


Nota 1: $q_{ij} \in [-1, 1]$ no cumple $0 \leq s \leq 1$. Se puede adaptar como:

$$s_{ij} = |q_{ij}| \quad \text{o} \quad s_{ij} = 1 - q_{ij}^2$$


Nota 2: Igual para el coseno $c_{ij} \in [-1, 1]$:

$$s_{ij} = |c_{ij}| \quad \text{o} \quad s_{ij} = 1 - c_{ij}^2$$

Métodos de agrupación en análisis cluster



Dendrogramas



Ejemplo de dendrograma

Interpretación visual

- **Alturas bajas:** objetos similares se agrupan.
- **Alturas altas:** se fusionan grupos disímiles.
- Cortes horizontales definen el número k de clusters.

Nota

Solo importa la **altura vertical**. La posición horizontal es irrelevante.

Método jerárquico aglomerativo: método de Ward (Idea general)

Combina los clústeres cuya fusión genere el menor incremento en el valor total de la suma de los cuadrados de las diferencias entre cada elemento y el centroide del cluster.

Notación

- x_{ij}^k : valor de la j -ésima variable del i -ésimo individuo en el k -ésimo clúster (n_k individuos).
- m_j^k : j -ésima componente del centroide del clúster C_k .
- E_k : suma de cuadrados internos del clúster k :

$$E_k = \sum_{i=1}^{n_k} \sum_{j=1}^n (x_{ij}^k - m_j^k)^2 = \sum_{i=1}^{n_k} \sum_{j=1}^n (x_{ij}^k)^2 - n_k \sum_{j=1}^n (m_j^k)^2$$

- $E = \sum_{k=1}^h E_k$: error total (suma de errores por clúster).

Método jerárquico aglomerativo: método de Ward (Idea general)

Inicialmente, $E_k = 0$ (cada clúster tiene un solo individuo). En cada paso se fusionan los clústeres C_p y C_q que minimizan ΔE_{pq} .

Incremento del error al fusionar C_p y C_q

$$\Delta E_{pq} = \frac{n_p n_q}{n_p + n_q} \sum_{j=1}^n (m_j^p - m_j^q)^2$$

Sea $C_t = C_p \cup C_q$ (fusión de clústeres) y C_r un tercer clúster. El incremento en E al unir C_t y C_r es:

$$\Delta E_{rt} = \frac{n_r n_t}{n_r + n_t} \sum_{j=1}^n (m_j^r - m_j^t)^2$$

Método jerárquico aglomerativo: método de Ward (Idea general)

Donde:

$$n_t m^t = n_p m^p + n_q m^q \quad \Rightarrow \quad m_j^t = \frac{n_p m_j^p + n_q m_j^q}{n_p + n_q}$$

Sustituyendo y desarrollando, se obtiene la fórmula recursiva:

$$\Delta E_{rt} = \frac{1}{n_r + n_t} [(n_r + n_p) \Delta E_{rp} + (n_r + n_q) \Delta E_{rq} - n_r \Delta E_{pq}]$$

Método no jerárquico: *k-means* (¿Qué es?)

Método no jerárquico propuesto por MacQueen (1967). Divide los datos en k grupos predefinidos, asignando cada punto al **centroide más cercano**.

Funcionamiento

- Se eligen k *semillas* iniciales (centroides).
- Cada punto se asigna al cluster más cercano (distancia euclídea).
- Se recalculan los centroides tras cada asignación.
- Se repite hasta minimizar el **Error Cuadrático Medio (ECM)**:

$$ECM = \sum_{j=1}^k \sum_{i \in C_j} (x_i - \bar{x}_j)' (x_i - \bar{x}_j)$$

Método no jerárquico: *k-means* (ventajas y limitaciones)

- Permite reasignar puntos entre clusters (mejor que métodos jerárquicos).
- Muy eficiente, ideal para grandes conjuntos de datos.
- **Sensible a las semillas:** distintos resultados si no se eligen bien.

Determinación del número óptimo de clusters




Figure 2: Método del codo (Fuente: elaboración propia).




Figure 3: Método de la silueta (Fuente: elaboración propia).

Proyecto Gene Expression Omnibus (GEO)

Gene Expression Omnibus (GEO) es una base de datos pública del **NCBI** para almacenar y compartir estudios de expresión génica y datos genómicos funcionales.

Objetivos principales de GEO

- **Almacenamiento:** Repositorio robusto y versátil de datos genómicos.
- **Envío:** Facilitar el depósito de datos bien anotados.
- **Acceso:** Proveer herramientas intuitivas para búsqueda, visualización y descarga.

Organización de los datos: entidades principales

La base de datos se estructura en tres entidades principales:

- **Platform (GPL)**: define el diseño del array o secuenciador.
- **Sample (GSM)**: describe condiciones experimentales y datos de expresión.
- **Series (GSE)**: agrupa Samples relacionados y describe el experimento completo.

Observación

Estas entidades siguen un modelo Entidad-Relación, con enlaces lógicos y cardinalidades bien definidas. Los archivos crudos se almacenan en un servidor FTP externo.

Organización de los datos: entidades principales




Figure 4: Diagrama Entidad-Relación (Fuente: elaboración propia).

¿Qué es Bioconductor?

Proyecto de código abierto con paquetes para R enfocados en el análisis de datos ómicos (microarrays, secuenciación, transcriptómica espacial).


Objetivos principales

- Acceso a métodos estadísticos y gráficos avanzados.
- Incorporación de metadatos biológicos.
- Plataforma extensible, escalable y reproducible.
- Documentación clara y formación en análisis genómico.

Integración con GEO

El paquete GEOquery permite importar datos de GEO en R, estructurarlos y convertirlos a objetos estándar de Bioconductor (ExpressionSet, MAList, etc.).

Análisis y especificación de requisitos



Diseño de la aplicación

Interfaz de usuario (UI)

Define qué va a ver el usuario, la estructura de navegación y los elementos interactivos que la componen.

Servidor (server)

Contiene toda la lógica que hay por debajo en cuanto a procesamiento de datos y generación de resultados.

Análisis multivariante de datos RNA-seq

UNIVERSIDAD DE GRANADA

Paso 1: Seleccione su archivo (.csv/.tsv) con la matriz de expresión.

Sube tu archivo CSV/TSV

No file selected

Paso 2: Indique el separador de columnas de su fichero.

Separador

☐ Coma

☐ Punto y coma

☐ Tab

Paso 3: Seleccione cómo se escriben los decimales en su fichero.

Símbolo decimal

☐ Punto


☐ Coma

Paso 4: Pulse este botón para cargar los datos.

PCA Analítica Cluster Expresión diferencial

Manual de Usuario Descargar código fuente Contacto

Aplicación práctica



¡Es hora de probar la aplicación web!

link: pon el link de la aplicación web aquí